Stefan Kurtz Christina de Bruyn Kops

Universität Hamburg Zentrum für Bioinformatik

Grundlagen der Sequenzanalyse Wintersemester 2016/2017 Übungen zur Vorlesung: Ausgabe am 06.12.2016

Punkteverteilung:

Aufgabe 8.1: 6 Punkte, Aufgabe 8.2: 4 Punkte,

Abgabe bis zum 12.12.

Aufgabe 8.1 Implementieren Sie in Ruby oder in C ein Programm zur Berechnung der Koordinaten optimaler lokaler Alignments mit Hilfe des Smith-Waterman-Algorithmus. Ihr Programm soll folgendermaßen aufgerufen werden:

swalign.<suffix> indelscore scorematrixfile inputfile

Dabei ist

- suffix der von der verwendeten Programmiersprache abhängige Suffix des ausführbaren Programms, also z.B. x für das ausführbare (also compilierte und durch den Linker prozessierte) C-Programm oder rb für ein Ruby-Skript.
- indelscore ist der Score für Einfügungen und Löschungen, in diesem Kontext ein negativer Integer.
- scorematrixfile ist der Dateiname für die Similarity-Scorematrix im Format des Programms Blast.
- inputfile ist der Name einer Datei, die mindestens zwei Zeilen enthält. Jede einzelne Zeile wird als Sequenz betrachtet und Ihr Programm soll alle Paare gegen alle anderen vergleichen. Falls die Datei n Zeilen, also n-Sequenzen s_0, \ldots, s_{n-1} enthält, dann sollen alle Paare s_i, s_j mit $0 \le i < j \le n-1$ verglichen werden.

Damit Sie sich auf das Wesentliche konzentrieren können, finden Sie im Material zu dieser Aufgabe einen Testrahmen (in C und Ruby), Testdaten (Proteinsequenzen) und die erwarteten Ergebnisse:

Hinweise zum Testrahmen in Ruby (siehe ruby-solution)

- all_against_all.rb enthält einen Iterator, der für eine gegebene Sequenzdatei alle oben definierten Sequenzpaare aufzählt.
- scorematrix.rb enthält eine Klasse zum Einlesen einer Scorematrix.
- swalign.rb liest die Scorematrix ein, deklariert für Ihre Anwendung relevante Strukturen, zerlegt das ARGV-Array, nutzt den Iterator zum Aufzählen der Sequenzpaare und liefert die Ergebnisse im passenden Format. Sie selbst müssen in dieser Datei nur die Methode smithwaterman_algorithm implementieren. Die entsprechende zu füllende Struktur und die return-Anweisung sind bereits eingefügt. Die Struktur speichert 5 Werte, nämlich (in dieser Reihenfolge):

- 1. die Startposition des alignierten Substrings in der Sequenz u
- 2. die Länge des alignierten Substrings in u,
- 3. die Startposition des alignierten Substrings in der Sequenz v
- 4. die Länge des alignierten Substrings in v,
- 5. den Score des optimalen lokalen Alignments

Damit Ihre Lösung exakt der erwartenden Lösung entspricht, müssen Sie für den Fall, dass es in der Matrix L_{σ} mehrere Einträge mit dem gleichen maximalen Score-Wert gibt, bestimmte Auswahlregeln beachten. Diese sind in der Datei swalign. h beschrieben.

- Durch make test-gsa wird ein minimaler Test mit den beiden Sequenzen aus dem GSA-Script durchgeführt, die Sie in der Datei gsa-seqpair.txt finden. Die verwendete Scorematrix steht in unitscore.txt. Das erwartete Ergebnis steht in gsa-align.txt. Wenden Sie Ihr Programm zunächst auf diesen Testfall an. Die Suche nach Fehlern wird erleichtert, da die Berechnung des Ergebnisses im GSA-Skript detailliert dokumentiert ist.
- Durch make test-small wird ein Test mit 18 Sequenzen aus der Datei seq18.txt, dem Indelscore —4 und der Scorematrix aus der Datei blosum62.txt durchgeführt. Das erwartete Ergebnis finden Sie in der Datei align18.txt.

Hinweise zum Testrahmen in C:

Dieser Testrahmen besteht aus 6 C-Dateien und 5 Header Dateien, deren Verständnis für diese Aufgabe nicht wichtig ist.

Zum Compilieren der C-Sourcen verwenden Sie make. Sie müssen lediglich in der Datei swalign.c eine Funktion

implementieren. Diese soll die durch useq und vseq referenzierten Sequenzen der Längen ulen und vlen alignieren. Dabei sind die Scores durch die Parameter scorematrix, insertionscore und deletionscore bestimmt. Sie müssen die Funktion

aufrufen, um den Score für ein Zeichenpaar a und b zu ermitteln. Ein Zeichen aus den zu alignierenden Sequenzen wird Ihnen im Testrahmen als Index im Wertebereich von 0 bis 22 zur Verfügung gestellt. Dieses vereinfacht den Zugriff auf die Scorematrix.

Die Koordinaten eines optimalen lokalen Alignments werden in coords gespeichert. Die einzelnen Komponenten entsprechen denen in der Ruby-Struct, die oben beschrieben wurde. Damit Ihre Lösung exakt der erwarteten Lösung entspricht, müssen Sie für den Fall, dass es in L_{σ} mehrere

Einträge mit dem gleichen maximalen Score-Wert gibt, bestimmte Auswahlregeln beachten. Diese sind in der Datei swalign. h beschrieben.

Überlegen Sie, welche Informationen und Funktionen zusätzlich zu der DP-Matrix noch zur Berechnung der Koordinaten eines optimalen lokalen Alignments notwendig sind und erweitern Sie ggf. Ihren Programmcode aus früheren Übungen um die entsprechende Funktionalität. Überlegen Sie sich auch, wie Sie am einfachsten die Startpositionen der optimalen lokalen Alignments bestimmen können. Ein offensichtliche Lösung über Backtracing benötigt O(mn) Platz. Es gibt auch eine Lösung ohne Backtracing, die sich in O(m) Platz implementieren lässt. Falls Sie diese Lösung implementieren, können Sie zur Vereinfachung auch O(mn) Platz verwenden.

Ihr Programm sollte die beiden Tests test-gsa und test-small (siehe Makefile) bestehen.

Aufgabe 8.2 Eine zentrale Funktion beim Linear-Space-Alignment-Algorithmus für zwei Sequenzen u (mit |u|=m) und v (mit |v|=n) ist die Funktion evaluateallcolumns (Details siehe Skript). Implementieren Sie diese Funktion und gehen Sie dabei schrittweise vor (so wie im Vorlesungsskript beschrieben), d.h.:

- 1. Implementieren Sie zuerst die Funktionen firstEDtabcolumn und nextEDtabcolumn.
- 2. Erweitern Sie diese Funktionen dann zu den Funktionen *firstEDtabRtabcolumn* und *nextEDtabRtabcolumn*.
- 3. Kombinieren Sie diese Funktionen zu der gewünschten Funktion evaluateallcolumns.

Stellen Sie sicher, dass nie mehr als O(m) Speicherplatz verwendet wird und keine (Sub-)Strings in mehrfacher Kopie erzeugt werden. Idealerweise allozieren Sie einmal zwei Arrays der Länge m+1 für E und R und überschreiben diese im Laufe des Algorithmus. Eine konstante Anzahl von Variablen kann dabei zur temporären Speicherung von Zwischenwerten verwendet werden.

Bitte die Lösungen zu diesen Aufgaben bis zum 12.12.2016 abgeben. Die Besprechung der Lösungen erfolgt am 13.12.2016.

Lösung zu Aufgabe 8.1:

Eine Lösung in C in linearem Platz ohne Backtracing

```
/*
Copyright (c) 2016 Stefan Kurtz <kurtz@zbh.uni-hamburg.de>
Copyright (c) 2016 Center for Bioinformatics, University of Hamburg
```

Permission to use, copy, modify, and distribute this software for any purpose with or without fee is hereby granted, provided that the above copyright notice and this permission notice appear in all copies.

THE SOFTWARE IS PROVIDED "AS IS" AND THE AUTHOR DISCLAIMS ALL WARRANTIES WITH REGARD TO THIS SOFTWARE INCLUDING ALL IMPLIED WARRANTIES OF MERCHANTABILITY AND FITNESS. IN NO EVENT SHALL THE AUTHOR BE LIABLE FOR ANY SPECIAL, DIRECT, INDIRECT, OR CONSEQUENTIAL DAMAGES OR ANY DAMAGES

```
WHATSOEVER RESULTING FROM LOSS OF USE, DATA OR PROFITS, WHETHER IN AN
  ACTION OF CONTRACT, NEGLIGENCE OR OTHER TORTIOUS ACTION, ARISING OUT OF
  OR IN CONNECTION WITH THE USE OR PERFORMANCE OF THIS SOFTWARE.
#include <stdbool.h>
#include <stdio.h>
#include <stdlib.h>
#include <assert.h>
#include "scorematrix.h"
#include "swalign.h"
typedef struct
  unsigned long aligned_u, aligned_v;
  Score score;
} LMatrixEntry;
typedef struct
  unsigned long start_row, start_column, aligned_u, aligned_v;
  Score score;
} BestCoordinate;
static void sw_eval_columns(BestCoordinate *maxscore_entry,
                            const Scorematrix *scorematrix,
                            Score insertionscore,
                            Score deletionscore,
                            const unsigned char *useq,
                            unsigned long ulen,
                            const unsigned char *vseq,
                            unsigned long vlen)
  unsigned long idx;
  const unsigned char *uptr, *vptr;
  LMatrixEntry *scol = malloc(sizeof *scol * (ulen + 1));
  assert (maxscore_entry != NULL);
  for (idx = 0; idx <= ulen; idx++)
    scol[idx].score = 0;
   scol[idx].aligned_u = 0;
    scol[idx].aligned_v = 0;
  }
  maxscore_entry->score = 0;
  maxscore_entry->start_row = 0;
  maxscore_entry->start_column = 0;
  maxscore_entry->aligned_u = 0;
  maxscore_entry->aligned_v = 0;
  for (vptr = vseq; vptr < vseq + vlen; vptr++)</pre>
```

const unsigned long column = (unsigned long) (vptr - vseq + 1);

for (scolptr = scol+1, uptr = useq; uptr < useq + ulen; scolptr++, uptr++)</pre>

LMatrixEntry nw = *scol, *scolptr;

{

```
#define MINIMIZE_BRANCHING
#ifdef MINIMIZE BRANCHING
      LMatrixEntry valnorth, valwest;
#else
      Score val;
#endif
      const LMatrixEntry we = *scolptr;
      scolptr->score = nw.score +
                       scorematrix_score_get(scorematrix,*uptr,*vptr);
      scolptr->aligned_u = nw.aligned_u + 1;
      scolptr->aligned_v = nw.aligned_v + 1;
#ifdef MINIMIZE_BRANCHING
      valnorth.score = (scolptr-1)->score + deletionscore;
      valnorth.aligned_u = (scolptr-1) ->aligned_u + 1;
      valnorth.aligned_v = (scolptr-1)->aligned_v;
      valwest.score = we.score + insertionscore;
      valwest.aligned_u = we.aligned_u;
      valwest.aligned_v = we.aligned_v + 1;
#define FIRSTWORSETHANSECOND(VAL1, VAL2) \
                   (((VAL1)->score > (VAL2)->score ||\
                   ((VAL1) \rightarrow score == (VAL2) \rightarrow score && \
                   (VAL1) -> aligned_u + (VAL1) -> aligned_v >= \
                   (VAL2)->aligned_u + (VAL2)->aligned_v)) ? false : true)
      if (FIRSTWORSETHANSECOND(scolptr,&valnorth))
        *scolptr = valnorth;
      if (FIRSTWORSETHANSECOND(scolptr, &valwest))
        *scolptr = valwest;
#else
      if ((val = (scolptr-1)->score + deletionscore) >= scolptr->score)
        if (val > scolptr->score)
          scolptr->score = val;
          scolptr->aligned_u = (scolptr-1)->aligned_u + 1;
          scolptr->aligned v = (scolptr-1)->aligned v;
        } else
        {
          if (scolptr->aligned_u + scolptr->aligned_v <</pre>
              (scolptr-1)->aligned_u + 1 + (scolptr-1)->aligned_v)
            scolptr->aligned_u = (scolptr-1)->aligned_u + 1;
            scolptr->aligned_v = (scolptr-1)->aligned_v;
          }
        }
      if ((val = we.score + insertionscore) >= scolptr->score)
        if (val > scolptr->score)
          scolptr->score = val;
          scolptr->aligned_u = we.aligned_u;
```

```
scolptr->aligned_v = we.aligned_v + 1;
        } else
           \textbf{if} \ (\texttt{scolptr->aligned\_u} \ + \ \texttt{scolptr->aligned\_v} \ < \\
              we.aligned_u + we.aligned_v + 1)
            scolptr->aligned_u = we.aligned_u;
            scolptr->aligned_v = we.aligned_v + 1;
        }
#endif
      if (scolptr->score > 0)
        if (maxscore_entry->score < scolptr->score ||
             (maxscore_entry->score == scolptr->score &&
             scolptr->aligned_u + scolptr->aligned_v >
                maxscore_entry->aligned_u + maxscore_entry->aligned_v))
          maxscore_entry->score = scolptr->score;
          maxscore_entry->start_row
            = (unsigned long) (scolptr - scol) - scolptr->aligned_u;
          maxscore_entry->start_column = column - scolptr->aligned_v;
          maxscore_entry->aligned_u = scolptr->aligned_u;
          maxscore_entry->aligned_v = scolptr->aligned_v;
        }
      } else
        scolptr->score = 0;
        scolptr->aligned_u = 0;
        scolptr->aligned_v = 0;
      nw = we;
    }
  free (scol);
void smithwaterman_algorithm(OptimalLocalAlignmentCoords *coords,
                              const Scorematrix *scorematrix,
                              Score insertionscore,
                              Score deletionscore,
                              const unsigned char *useq,
                              unsigned long ulen,
                              const unsigned char *vseq,
                              unsigned long vlen)
  BestCoordinate maxscoreentry;
  const bool keeporder = ulen < vlen ? true : false;</pre>
  sw_eval_columns(&maxscoreentry,
                   scorematrix,
                   insertionscore,
                   deletionscore,
                   keeporder ? useq : vseq,
                   keeporder ? ulen : vlen,
```

```
keeporder ? vseq : useq,
                  keeporder ? vlen : ulen);
  if (maxscoreentry.score > 0)
    if (keeporder)
      coords->ustart = maxscoreentry.start_row;
      coords->usubstringlength = maxscoreentry.aligned_u;
      coords->vstart = maxscoreentry.start column;
      coords->vsubstringlength = maxscoreentry.aligned_v;
    } else
    {
      coords->vstart = maxscoreentry.start_row;
      coords->vsubstringlength = maxscoreentry.aligned_u;
      coords->ustart = maxscoreentry.start_column;
      coords->usubstringlength = maxscoreentry.aligned_v;
    coords->score = maxscoreentry.score;
  } else
    coords->ustart = 0;
    coords->usubstringlength = 0;
    coords->vstart = 0;
    coords->vsubstringlength = 0;
   coords->score = 0;
  }
}
void smithwaterman_algorithm_void(void *data,
                                  const unsigned char *useq,
                                  unsigned long ulen,
                                   const unsigned char *vseq,
                                  unsigned long vlen)
  SwalignScoresAndResult *sar = (SwalignScoresAndResult *) data;
  smithwaterman_algorithm(&sar->coords,
                          sar->scorematrix,
                          sar->insertionscore,
                          sar->deletionscore,
                          useq,
                          ulen,
                          vseq,
                          vlen);
```

Eine Lösung in Ruby in quadratischem Platz ohne Backtracing

Die Idee dieser Lösung ist, mit jedem Score-Wert in der DP-Matrix noch die Start-Koordinaten des entsprechenden lokalen Alignments zu speichern. D.h. immer dann, wenn ein Eintrag den Score 0 hat, beginnt ein lokales Alignment. Diese Koordinaten werden entlang der maximierenden Kanten vererbt. Um eindeutige Lösungen zu bekommen, bevorzugt man Ersetzungskanten vor Löschkan-

ten und Löschkanten vor Einfügekanten, für den Fall, dass es mehrere eingehende maximierende Kanten gibt.

```
#!/usr/bin/env ruby
require_relative '../Scorematrix_code/scorematrix.rb'
require 'all_against_all.rb'
def showdpmatrix(dptable,ulen,vlen)
  0.upto(vlen) do |j|
    0.upto(ulen) do |i|
      terminator = if i < ulen then " " else "\n" end
      print "#{dptable[i][j].score}#{terminator}"
    end
  end
end
SWentry = Struct.new("SWentry",:score, :start_u, :start_v)
OptimalLocalAlignmentCoords = Struct.new("OptimalLocalAlignmentCoords",
    :ustart, # start position of local opt. alignment in <useq>
    :usubstringlength, # length of substring of local opt. align. in <useq>
    :vstart, # start position of local opt. alignment in <vseq>
    :vsubstringlength, # length of substring of local opt. align. in <vseq> */
    :score)
def smithwaterman_algorithm(scorematrix,insertionscore,deletionscore,useq,vseq)
  ulen = useq.length
  vlen = vseq.length
  optimalAlignedCoords = OptimalLocalAlignmentCoords.new(0,0,0,0,0)
             # coordinates of substring pair with optimal loc. alignment
  maxrow = 0 # maxrow + maxcolumn are maximum sum of end coordinates seen so far
  maxcolumn = 0
  dptable = Array.new(ulen+1) { Array.new(vlen+1) { SWentry.new(0,0,0) } }
  0.upto(ulen) do |i|
    dptable[i][0].score = 0
    dptable[i][0].start_u = i
    dptable[i][0].start_v = 0
  1.upto(vlen) do |j|
    dptable[0][j].score = 0
    dptable[0][j].start_u = 0
    dptable[0][j].start_v = j
    1.upto(ulen) do |i|
      nws = dptable[i-1][j-1].score +
            scorematrix.getscore(useq[i-1].chr, vseq[j-1].chr)
      ns = dptable[i-1][j].score + deletionscore
      ws = dptable[i][j-1].score + insertionscore
      dptable[i][j].score = [nws, ns, ws].max
      if dptable[i][j].score <= 0</pre>
        dptable[i][j].score = 0
        dptable[i][j].start u = i
        dptable[i][j].start_v = j
        dptable[i][j].start_u = nil
        dptable[i][j].start_v = nil
        maxval = nil
```

```
[[nws, i-1, j-1], [ns, i-1, j], [ws, i, j-1]].each do <math>|s, p, q|
          if s == dptable[i][j].score and (maxval.nil? or
             (maxval > dptable[p][q].start_u + dptable[p][q].start_v))
            dptable[i][j].start_u = dptable[p][q].start_u
            dptable[i][j].start_v = dptable[p][q].start_v
            maxval = dptable[i][j].start_u + dptable[i][j].start_v
          end
        end
        if optimalAlignedCoords.score < dptable[i][j].score or</pre>
           (optimalAlignedCoords.score == dptable[i][j].score and
            i - dptable[i][j].start_u + j - dptable[i][j].start_v >
              optimalAlignedCoords.usubstringlength +
              optimalAlignedCoords.vsubstringlength)
          optimalAlignedCoords.score = dptable[i][j].score
          optimalAlignedCoords.ustart = dptable[i][j].start_u
          optimalAlignedCoords.usubstringlength = i - dptable[i][j].start_u
          optimalAlignedCoords.vstart = dptable[i][j].start_v
          optimalAlignedCoords.vsubstringlength = j - dptable[i][j].start_v
        end
      end
    end
  end
  return optimalAlignedCoords
end
if ARGV.length != 3
  STDERR.puts "Usage: #{$0} indelscore scorematrixfile sequencefile"
  exit
end
indelscore = ARGV[0].to_i
scorematrixfile = ARGV[1]
scorematrix = Scorematrix.new(scorematrixfile)
sequencefile = ARGV[2]
all_against_all(sequencefile) do |i,j,useq,vseq|
  result = [i,j]
  if useq.length < vseq.length</pre>
    maxscorealign = smithwaterman_algorithm(scorematrix,indelscore,indelscore,
                                             useq, vseq)
    result.push (maxscorealign.ustart)
    result.push (maxscorealign.usubstringlength)
    result.push (maxscorealign.vstart)
    result.push (maxscorealign.vsubstringlength)
  else
    maxscorealign = smithwaterman_algorithm(scorematrix,indelscore,indelscore,
                                             vseq, useq)
    result.push(maxscorealign.vstart)
    result.push (maxscorealign.vsubstringlength)
    result.push (maxscorealign.ustart)
    result.push (maxscorealign.usubstringlength)
  result.push (maxscorealign.score)
  puts result.join("\t")
end
```

Lösung zu Aufgabe 8.2:

Hier ist der erste Teil der Lösung. Der Rest des Codes folgt im Kontext einer weiteren Übungsaufgabe.

```
#define ADDUNIT(A,B) ((A) == (B) ? 0 : 1)
#define GAP ((unsigned char) '-')
#define DIV2(N)
                   ((N) >> 1)
   The following function computes the first column of the E and R table as
   described in the handout of the lecture on ''A Linear Space Alignmen
  Algorithm''. EDtabcolumn takes a column of the E table and should
  contain the first column after completion of the function. Analog,
  Rtabcolumn takes a column of the R table and should contain the first column
  after completion of the function (this is the initialization!).
  ulen is the length of the first sequence.
static void firstEDtabRtabcolumn(unsigned int *EDtabcolumn,
                                 unsigned int *Rtabcolumn,
                                 unsigned int ulen)
{
 unsigned int rowindex;
 for (rowindex=0; rowindex <= ulen; rowindex++) {</pre>
   EDtabcolumn[rowindex] = rowindex;
   Rtabcolumn[rowindex] = rowindex;
}
   The following function computes a column of the E and R table under the
  assumption that EDtabcolumn and Rtabcolumn contain the previous columns
  of the corresponding tables. The function overwrites EDtabcolumn and
  Rtabcolumn with the new columns. b is the character of the
   sequence vseq corresponding to to column which needs to be calculated. Useq
  is the first sequence and ulen its length.
   colindex is the number of the column to be calculated and midcolumn
   is the column, where the tables are divided.
static void nextEDtabRtabcolumn(unsigned int *EDtabcolumn,
                                unsigned int *Rtabcolumn,
                                unsigned int colindex,
                                unsigned int midcolumn, unsigned char b,
                                const unsigned char *useq, unsigned int ulen)
 unsigned int rowindex, val,
               northwestEDtabentry,
               westEDtabentry = EDtabcolumn[0], /* saves the first entry of
                                                   EDtabcolumn */
               northwestRtabentry,
               westRtabentry = 0;
 bool updateRtabcolumn = false;
 EDtabcolumn[0]++;
  if (colindex > midcolumn) {
```

```
updateRtabcolumn = true;
  for (rowindex = 1; rowindex <= ulen; rowindex++) {</pre>
    northwestEDtabentry = westEDtabentry;
    northwestRtabentry = westRtabentry;
    westEDtabentry = EDtabcolumn[rowindex];
    westRtabentry = Rtabcolumn[rowindex];
    EDtabcolumn[rowindex]++; /* 1. recurrence (Insertion) */
    /* Rtabcolumn[rowindex] is unchanged */
    /* 2. recurrence (Replacement): */
    val = northwestEDtabentry + ADDUNIT(useq[rowindex-1],b);
    if (val < EDtabcolumn[rowindex]) {</pre>
     EDtabcolumn[rowindex] = val;
      if (updateRtabcolumn)
        Rtabcolumn[rowindex] = northwestRtabentry;
    /* 3. recurrence (Deletion): */
    val = EDtabcolumn[rowindex-1]+1;
    if (val < EDtabcolumn[rowindex]) {</pre>
     EDtabcolumn[rowindex] = val;
      if (updateRtabcolumn)
        Rtabcolumn[rowindex] = Rtabcolumn[rowindex-1];
}
   The following function computes the rightmost EDtabcolumn and Rtabcolumn.
  midcolumn is the actual column, where the tables are divided.
  useq and vseq are the sequences with the corresponding length ulen and vlen.
static unsigned int evaluateallcolumns (unsigned int *EDtabcolumn,
                                        unsigned int *Rtabcolumn,
                                        unsigned int midcol,
                                        const unsigned char *useq,
                                        const unsigned char *vseq,
                                        unsigned int ulen, unsigned int vlen)
 unsigned int colindex;
  firstEDtabRtabcolumn(EDtabcolumn, Rtabcolumn, ulen);
  for (colindex = 1; colindex <= vlen; colindex++) {</pre>
    nextEDtabRtabcolumn(EDtabcolumn, Rtabcolumn, colindex, midcol,
                        vseq[colindex-1], useq, ulen);
 return EDtabcolumn[ulen];
```